SQL FOR DATA ANALYSIS

انا دلوقتى هشتغل على داتا CSV_file حملته من على الانترنت و حطيته عندى على الجهاز عشان استخدمه و اعمل عليه Analysis و اطلع المعلومات اللي المدير طالبها منى على هيئه Dashboard او Report مثلا

Life cycle of Data Analysis:

1- Source Systems:

ده المكان اللي حملت منه الداتا من الانترنت و اللي هو هنا ال Web Page

2- Data Warehouse:

ده المكان اللي حطيت فيه الداتا على postgres بعد ما حملتها

3- Queries and Analysis:

ده بقى الجزء بتاع ال Data analyst

4- Presentation

ال dashboard او ال report النهائي

QUERIES AND ANALYSIS HAVE 5 STEPS:

1- Exploration:

دلوقتى انا معايا الداتا بس معرفش هى عباره عن ايه يعنى معرفش الداتا دى بتتكلم عن ايه ماهو اكيد اسم الفايل من برا مش هيعرفنى الداتا كلها من جوا فأنا لازم اعرف كل حاجه عن الداتا علشان اعرف هعمل analysis ازاى و هطلع منها ايه يفيد ال business حتى لو اضطريت اروح للى مسجل الداتا دى المهم انى اعرف كل business للدانتا دى يمثل ايه و ده اللى اسمه ال Data Dictionary يعنى اترجم من ال column name

2- Profiling:

بعد ما عرفت الداتا بتتكلم عن ايه و فهمت كل column بيمثل ايه بالظبط

لازم اعرف التوزيع بتاع الداتا دى ازاى علشان لما اعملها analysis ابقى فاهم هعمل ايه بالظبط لان مثلا الداتا لو normalization غير لما تبقى skewed اكيد كل ده هيفرق معايا حتى لما اجى اعمل skewed للارقام فى مرحله الML

يعنى من الاخر مثلا ايه ال columns اللى تهمنى اكتر طب و هتعامل معاها ازاى يعنى الحاجات اللى فيها nulls كتيره اوى دى؟ فلازم يبقى في standard امشى بيه

3- Cleaning:

نضافه الداتا مهمه اوى يعنى مثلا اشيل ال special characters اللى فى الstrings زى !@#\$%<>|+_ و ال null دى بقى هسال فيها ال business مثلا عاوز بداله °0 ولا اشيلها ولا اسببها زى ماهى ولا ايه 4- Shape:

شكل الداتا دى بقى بعد ما خلصت اول 3 مراحل و بقيت جاهزه لل analysis و مفيش حاجه توقفنا بطلع بقى شويه statistics منها زى مثلا Max/Min/SD/...etc

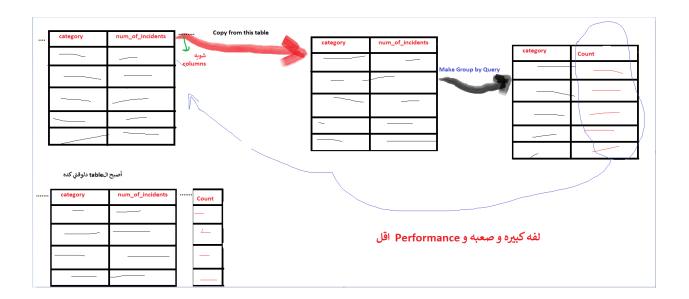
5- Analysis

هنا بقى ببدأ اعمل analysis اللي هو اصلا انا مستنيهدورك جه

Window Function:

انا دلوقتي لو معايا table كبير في fields كتيره منهم category و number of incidents و انا عاوز اعمل noumber of incidents في حلول:

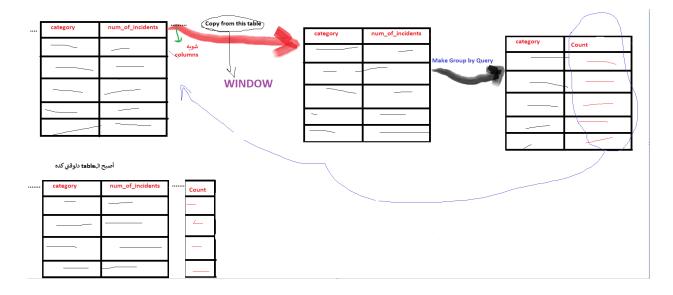
- 1- انا لو عملته بالطريقه العاديه بتاع count و count فكده هيطلع table واحد مكون من count 2 count بس اللي عاملهم select و هيطلع فعلا column جديد فيه ال count لكن مش ده اللي انا عاوزه ... انا عاوز اطلع ال table بتاع ال database كلللللللللللللله و زياده عليه ال column
 - 2- الطريقه التانيه و الصعبه



عندي الtable هاخد منه copy و اعمل عليه الquery هيطلعلي الcount اللي انا عاوزه هاخده احطه مع المtable الاصلي

3- في بقى طريقه احسن و انضف و اشيك ألا و هي ال WINDOW FUNCTION

ال window دي اللي هي الcopy فتتم ال query او ال(..... copy) و الله window دي اللي هي الtable فتتم ال directly الاصلى و النتيجه تضاف table الاصلى و النتيجه تضاف directly لل



کل ده بیحصل ب window function اسمها

Over()→ take copy from all table and do the aggregate function that you need without group by and the result will concatenated to the original table directly.

Over(Partition by + column name)→ same Over() but the window will be copy of the specified column

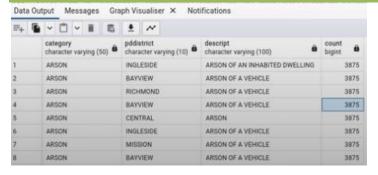
-- take a window of the full table



-- change the scope of the window to the category alone

انما هنا هيجيب عدد كل category موجوده في category column و هيبقي مش شايف باقي الcolumns

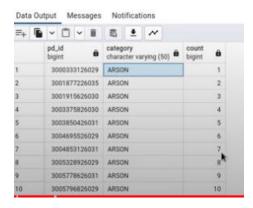
Select category, pddistrict, descript, count(incidentnum) over(partition by category) from police_incident_reports

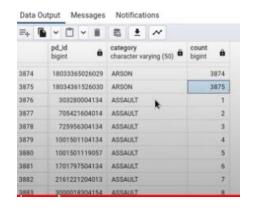


بالنسبه لتأثير ال order by بقي هنا هيبقي عباره عن running counter كده بيزيد كل ما يشوف الcategory يعني لو عندي category اسمها Arson هتبقي 1 لما يشوفها تاني هتبقي 2 اللي بعدها 3 و هكذا لحد ما اول Arson تخلص و تيجي category تانيه مثلا اسمها Assault فهيصفر العداد و يبدا من الاول

-- running count of pd id by incident category

SELECT pd_id, category, count(pd_id) over(partition by category order by pd_id) from public.police_incident_reports;





أكيد لاحظت صح؟!

Row_number()→ it's equal to count()

SELECT pd_id, category, **count(pd_id)** over(partition by category order by pd_id) from public.police incident reports;

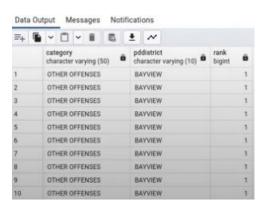
Equals to

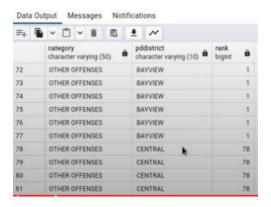
select category, pd_id, date, **row_number()** over(partition by category) from police_incident_reports

Rank()→ give rank to the selected values

یعنی بص کده

select category, pddistrict, rank() over(partition by "Incident Code" order by pddistrict) from police incident reports



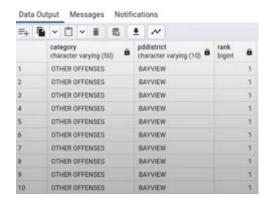


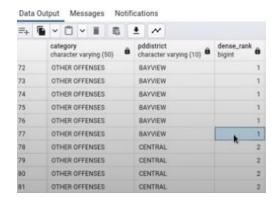
الصوره اللي على الشمال هنلاقي ان مفيش حاجه تميز ال rows عن بعضها فمفيش داعي ان ال value تتغير اصلا

الصوره اللي علي اليمين هنلاقي ان اول value تتغير اتغير معاها ال rank علطول بس هنا بقي بعد الواحد خد 78 علطول احتسابا ان في 77 row قبل كده و ده ال78

بس احنا اتعلمنا ان العد بيبقي-4-3-2-1 كده احنا هنروح ل Another Function بتعد العد بتاعنا

نفس فكره الاول و الاول مكرر بالظبط لما بيخلص بيجي التاني و التاني مكرر و هكذا → (Dense_Rank()





الصوره اللي على الشمال نفس ال () rank العاديه

الصوره اللي على اليمين هنلاقي ان اول value تتغير اتغير معاها ال rank علطول بس هنا بقي بعد الواحد خد 2

Example:

```
select first_name,last_name, department_id, salary,
        ank () over(partition by department_id order by salary desc) as rank ,
        ense_rank () over(partition by department_id order by salary desc) as dense
100 %
first_name
                   last_name
                                department_id
                                                      salary
                                                                       dense_rank
      Shelley
                                                       12000.00
1
                   Higgins
                                Accounting
      William
                                                       8300.00
                                                                 2
                                                                       2
2
                   Gietz
                                Accounting
                                                       13000.00
3
      Michael
                   Hartstein
                                Accounting Manager
                                                       6000.00
      Pat
                   Fay
                                Accounting Manager
5
      Den
                   Raphaely
                                Administration Assistant
                                                       11000.00
                                                                       2
6
      Alexander
                   Khoo
                                Administration Assistant
                                                      3100.00
                                                                       3
7
      Shelli
                   Baida
                                Administration Assistant
                                                      2900.00
                                                                       4
8
      Sigal
                   Tobias
                                                      2800.00
                                Administration Assistant
9
      Guy
                   Himuro
                                Administration Assistant
                                                      2600.00
                                                                       5
10
      Karen
                   Colmenares
                                Administration Assistant
                                                      2500.00
                                                       24000.00
11
      Steven
                   King
                                Executive
                   Kochhar
                                Executive
                                                       17000.00
                                                                       2
12
                   De Haan
                                                       17000.00
                                                                       2
13
                                Executive
      Lex
                                                       12000.00
                                                                       1
14
      Nancy
                   Greenberg
                                Finance
                                                                       2
      Daniel
                   Faviet
                                Finance
                                                       9000.00
15
                   Chen
                                                                       3
      John
                                Finance
                                                       8200.00
16
                                                                       4
17
      Jose Manuel
                   Urman
                                Finance
                                                       7800.00
                                                       7700.00
                                                                       5
18
      Ismael
                   Sciarra
                                Finance
                                                                       6
                                                       6900.00
                                                                 6
19
      Luis
                   Popp
                                Finance
20
      Alexander
                   Hunold
                                ΙT
                                                       9000.00
                                                                       1
                                                                       2
21
      Bruce
                   Ernst
                                ΙT
                                                       6000.00
                                ΙT
22
      David
                   Austin
                                                       4800.00
                                                                 3
                                                                       3
23
      Valli
                   Pataballa
                                ΙT
                                                       4800.00
                                                                       3
```

هنا انا بقوله اعمل window علي ال department_id يعني امسك كل department و هات ال salary بتاعه و رتبهم بناءا على ال salary

 $Lag() \rightarrow$

بتقولى اللى قبله في ال rank كان ايه او كان كام

Lead()→

بتقولي اللي بعده في ال rank ايه او كام

Example:

select first name, last name, department id, salary, .ead (salary,1) over(partition by department_id order by salary desc) as lead , (salary,1) over(partition by department_id order by salary desc) as lag from employees 100 % - ▼ - 4 ⊞ Results first_name department_id salary lead lag 8300.00 NULL Shellev Higgins 12000.00 Accounting 2 William Gietz 8300.00 NULL 12000.00 Accounting 3 Accounting Manager 6000.00 NULL Michael Hartstein 13000.00 6000.00 13000.00 4 Pat Fay Accounting Manager NULL 5 11000.00 3100.00 NULL Den Raphaely Administration Assistant 2900.00 6 Alexander Khoo Administration Assistant 3100.00 11000.00 7 Shelli 2800.00 3100.00 Baida Administration Assistant 2900.00 8 Sigal Tobias Administration Assistant 2800.00 2600.00 2900.00 9 Guy Himuro Administration Assistant 2600.00 2500.00 2800.00 10 Colmenares Administration Assistant 2500.00 NULL 2600.00 Karen 11 King Executive 24000.00 17000.00 NULL Steven Kochhar 17000.00 17000.00 24000.00 12 Neena Executive 17000.00 NULL 17000.00 13 Lex De Haan Executive 9000.00 14 Nancy Greenberg Finance 12000.00 NULL 15 Daniel Faviet Finance 9000.00 8200.00 12000.00 Finance 8200.00 7800.00 9000.00 16 John Chen 7700.00 17 Jose Manuel Finance 7800.00 8200.00 Urman 18 Ismael Sciarra Finance 7700.00 6900.00 7800.00 19 Luis Popp Finance 6900.00 NULL 7700.00 20 Alexander Hunold ΙT 9000.00 6000.00 NULL ΙT 4800.00 9000.00 21 Ernst 6000.00 Bruce ΙT 4800.00 4800.00 6000.00 22 David Austin ΙT 4800.00 4200.00 4800.00 23 Valli Pataballa

طب و ایه Null اللي موجوده دي؟

مش احنا عاملين الwindow علي ال department_id ف دي معناها ان في lead مفيش حد ال rank بتاعه اعلي من العلى الع

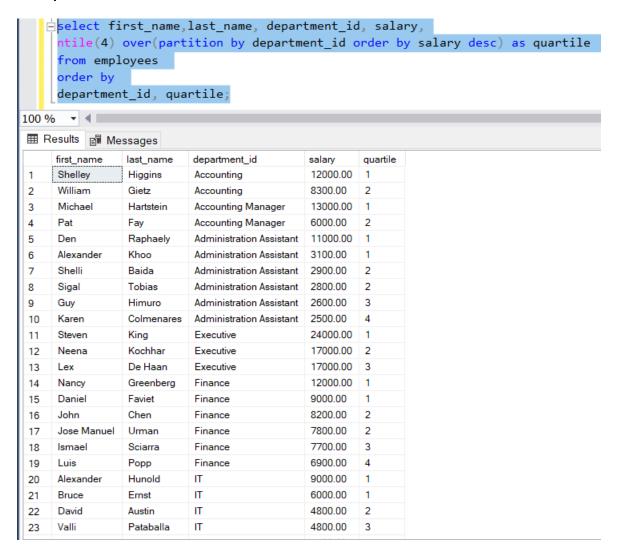
و معناها ان في lag مفيش حد ال rank بتاعه اقل من ال value اللي جنب الالله و ليكن اول null يعني مفيش في الله Accounting حد السالري بتاعه اقل من 12000

Ntile()→

Its an abbreviation to percentage tile, it's a statistical function

دى بتقسم الحاجه ل buckets او ranges

Example:



هنا ال window علي الdepartment_id يعني بيمسك كل department_id اللي جواه ل 4 ranges